

# Filtr Kalmana

Zygmunt Zawadzki, Mateusz Stachnik

13 maja 2014

## Spis treści

<b>1</b>	<b>Wstęp</b>	<b>1</b>
<b>2</b>	<b>Pewne zabawy z rozkładem apriori i aposterori</b>	<b>1</b>
<b>3</b>	<b>Filtr Kalmana</b>	<b>3</b>
3.1	Przykład modelu . . . . .	4
3.2	Równania w filtrze Kalmana . . . . .	4
3.3	Wyprowadzenie wzorów - faza predykcji . . . . .	5
3.4	Wyprowadzenie wzorów - faza uaktualnienia - intuicyjnie . . . . .	6
3.5	Wyprowadzanie wzorów - uaktualnianie . . . . .	7
<b>4</b>	<b>Prosta implementacja filtra Kalmana w R</b>	<b>8</b>

## 1 Wstęp

Dokument ten stanowi zbiór notatek dotyczących filtru Kalmana.

## 2 Pewne zabawy z rozkładem apriori i aposterori

Zakładamy, że rozkład próbkowy jest to jednowymiarowy rozkład normalny (mamy tylko jedną obserwację), o wartości oczekiwanej  $\mu$  i znanej wariancji  $\sigma^2$ :

$$p_x(x|\mu) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad (1)$$

, natomiast rozkład a priori również jest rozkładem normalnym o wartości oczekiwanej  $\theta$  i wariancji  $\tau^2$ .

$$p(\mu) = \frac{1}{\sqrt{2\pi\tau^2}} e^{-\frac{(\mu-\theta)^2}{2\tau^2}} \quad (2)$$

Korzystając z wzoru Bayesa możemy zapisać:

$$p(\mu|x) = \frac{p(x|\mu)p(\mu)}{p(x)} \propto p(x|\mu)p(\mu) \quad (3)$$

, Rozpisując:

$$p(x|\mu)p(\mu) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \frac{1}{\sqrt{2\pi\tau^2}} e^{-\frac{(\mu-\theta)^2}{2\tau^2}} \quad (4)$$

, dalej zauważając, że fragmenty  $\frac{1}{\sqrt{2\pi\sigma^2}}$  i  $\frac{1}{\sqrt{2\pi\tau^2}}$ , są niezależne od  $\mu$  i stałe można dalej zapisać, że:

$$p(x|\mu)p(\mu) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \frac{1}{\sqrt{2\pi\tau^2}} e^{-\frac{(\mu-\theta)^2}{2\tau^2}} \propto e^{-\frac{(x-\mu)^2}{2\sigma^2} + \frac{-(\mu-\theta)^2}{2\tau^2}} \quad (5)$$

Teraz należałoby pokazać, że uzyskane równanie jest jądrem znanego rozkładu (a najlepiej normalnego). Gdyby więc udało mi się zapisać 5 w postaci:

$$e^{-\frac{(\mu-\mu_{new})^2}{2\sigma_{new}^2}} \quad (6)$$

, wtedy natychmiast stwierdziłbym, że jest to jądro rozkładu normalnego i teraz wystarczy tylko dobrać odpowiednią stałą i mam gotowy rozkład a posteriori.

Należy więc dokonać paru prostych przekształceń, jednak w pewnym momencie należy zastosować pewną sztuczkę, dlatego przedstawię wszystko:-). Dla wygody rachunkowej chwilowo pozbywam się  $e$  i  $-\frac{1}{2}$  i całe równanie zapisuję jako:

$$\begin{aligned} \frac{(x-\mu)^2}{\sigma^2} + \frac{(\mu-\theta)^2}{\tau^2} &= \frac{x^2 + \mu^2 - 2x\mu}{\sigma^2} + \frac{\theta^2 + \mu^2 - 2\mu\theta}{\tau^2} = \\ &= \frac{(x^2 + \mu^2 - 2x\mu)\tau^2}{\sigma^2\tau^2} + \frac{(\theta^2 + \mu^2 - 2\mu\theta)\sigma^2}{\tau^2\sigma^2} = \\ &= \frac{(x^2 + \mu^2 - 2x\mu)\tau^2 + (\theta^2 + \mu^2 - 2\mu\theta)\sigma^2}{\sigma^2\tau^2} = \\ &= \frac{\mu^2(\sigma^2 + \tau^2) - 2\mu(\tau^2x + \sigma^2\theta) + \tau^2x^2 + \sigma^2\theta^2}{\sigma^2\tau^2} = \\ &= \frac{\mu^2(\sigma^2 + \tau^2)}{\sigma^2\tau^2} - \frac{2\mu(\tau^2x + \sigma^2\theta)}{\sigma^2\tau^2} + \frac{\tau^2x^2 + \sigma^2\theta^2}{\sigma^2\tau^2} \end{aligned} \quad (7)$$

Gdyby otrzymany wynik wstawić z powrotem do wyrażenia z  $e$ , otrzymamy:

$$e^{-\frac{1}{2}(\frac{\mu^2(\sigma^2+\tau^2)}{\sigma^2\tau^2} - \frac{2\mu(\tau^2x+\sigma^2\theta)}{\sigma^2\tau^2} + \frac{\tau^2x^2+\sigma^2\theta^2}{\sigma^2\tau^2})} \quad (8)$$

, porównując to z rozpisaniem wyrażeniem 6:

$$e^{-\frac{(\mu-\mu_{new})^2}{2\sigma_{new}^2}} = e^{-\frac{1}{2}(\frac{\mu^2}{\sigma_{new}^2} - \frac{2\mu\mu_{new}}{\sigma_{new}^2} + \frac{\mu_{new}^2}{\sigma_{new}^2})} \quad (9)$$

, można zauważyć, że są w sumie podobne. W tym momencie, by znaleźć wartość  $\mu_{new}$  i  $\sigma_{new}^2$ , dobrze jest wykonać pewną sztuczkę. Jeżeli zauważymy, że w równaniach 8 i 9, część  $\frac{\tau^2x^2+\sigma^2\theta^2}{\sigma^2\tau^2}$  i  $\frac{\mu_{new}^2}{\sigma_{new}^2}$ , nie zależą od  $\mu$ , znaczy to, że można je "wyrzucić" do mitycznej stałej normującej (analogiczny krok

jak w przypadku pozbywania się  $\frac{1}{\sqrt{2\pi\sigma^2}}$  i  $\frac{1}{\sqrt{2\pi\tau^2}}$  z rozkładu aposteriori - w zasadzie ciągle na nim pracujemy!). Dla utrzymania uwagi ten krok też przedstawię:

$$e^{-\frac{1}{2}(\frac{\mu^2(\sigma^2+\tau^2)}{\sigma^2\tau^2} - \frac{2\mu(\tau^2x+\sigma^2\theta)}{\sigma^2\tau^2} + \frac{\tau^2x^2+\sigma^2\theta^2}{\sigma^2\tau^2})} = e^{-\frac{1}{2}(\frac{\mu^2(\sigma^2+\tau^2)}{\sigma^2\tau^2} - \frac{2\mu(\tau^2x+\sigma^2\theta)}{\sigma^2\tau^2})} e^{-\frac{1}{2}\frac{\tau^2x^2+\sigma^2\theta^2}{\sigma^2\tau^2}} \propto$$

$$\propto e^{-\frac{1}{2}(\frac{\mu^2(\sigma^2+\tau^2)}{\sigma^2\tau^2} - \frac{2\mu(\tau^2x+\sigma^2\theta)}{\sigma^2\tau^2})} \quad (10)$$

$$e^{-\frac{1}{2}(\frac{\mu^2}{\sigma_{new}^2} - \frac{2\mu\mu_{new}}{\sigma_{new}^2} + \frac{\mu_{new}^2}{\sigma_{new}^2})} = e^{-\frac{1}{2}(\frac{\mu^2}{\sigma_{new}^2} - \frac{2\mu\mu_{new}}{\sigma_{new}^2})} e^{-\frac{1}{2}\frac{\mu_{new}^2}{\sigma_{new}^2}} \propto e^{-\frac{1}{2}(\frac{\mu^2}{\sigma_{new}^2} - \frac{2\mu\mu_{new}}{\sigma_{new}^2})}$$

,  
teraz już praktycznie koniec, teraz wystarczy przyrównać do siebie oba równania i wyliczyć  $\mu_{new}$  i  $\sigma_{new}^2$ . Z poniższej postaci:

$$e^{-\frac{1}{2}(\frac{\mu^2}{\sigma_{new}^2} - \frac{2\mu\mu_{new}}{\sigma_{new}^2})} = e^{-\frac{1}{2}(\frac{\mu^2(\sigma^2+\tau^2)}{\sigma^2\tau^2} - \frac{2\mu(\tau^2x+\sigma^2\theta)}{\sigma^2\tau^2})} \quad (11)$$

, od razu widać, że  $\sigma_{new}^2 = \frac{\sigma^2\tau^2}{\sigma^2+\tau^2}$ , natomiast przekształcając  $\frac{2\mu(\tau^2x+\sigma^2\theta)}{\sigma^2\tau^2}$  w  $\frac{2\mu(\tau^2x+\sigma^2\theta)(\sigma^2+\tau^2)}{\sigma^2\tau^2(\sigma^2+\tau^2)}$  i podstawiając  $\sigma_{new}^2$ , otrzymujemy  $\frac{2\mu(\tau^2x+\sigma^2\theta)}{\sigma_{new}^2(\sigma^2+\tau^2)}$ , łatwo więc zauważyć, że  $\mu_{new} = \frac{\tau^2x+\sigma^2\theta}{\sigma^2+\tau^2}$ .

Ostatecznie wartość oczekiwana rozkładu aposteriori:

$$\mu_{new} = \frac{\tau^2x + \sigma^2\theta}{\sigma^2 + \tau^2} \quad (12)$$

, i wariancja:

$$\sigma_{new}^2 = \frac{\sigma^2\tau^2}{\sigma^2 + \tau^2} \quad (13)$$

Patrząc na wzór 12 można zauważyć, że w zasadzie wartość oczekiwana, rozkładu aposteriori przy podanych założeniach, jest średnią ważoną wariancjami rozkładu apriori i aposteriori.

Pisząc ostatecznie trochę jednak przesadziłem, gdyż wzory 12 i 13 można przedstawić w trochę innej formie która pozwoli łatwo pewną zależność. W tym przypadku nie będę pisał wszystkich wyprowadzeń, są one dosyć trywialne (jeżeli jednak była by taka potrzeba - proszę mówić):

$$\mu_{new} = \theta + \frac{\tau^2(x - \theta)}{\sigma^2 + \tau^2} = \theta + \frac{\tau^2}{\sigma^2 + \tau^2}(x - \theta) \quad (14)$$

, i wariancja:

$$\sigma_{new}^2 = \tau^2 - \frac{\tau^4}{\sigma^2 + \tau^2} \quad (15)$$

Wzór 14 pokazuje, że wartość oczekiwana rozkładu aposteriori, to wartość oczekiwana apriori dodać przeskalowaną różnicą pomiędzy obserwacją i wartością oczekiwaną apriori. Podana będzie później kluczowa w pokazaniu czym jest filtr Kalmana.

### 3 Filtr Kalmana

W filtrze Kalmana przyjmuje się, że obserwowany jest pewien proces  $z_t$ , który bezpośrednio zależy od procesu ukrytego  $x_t$ . Oba procesy można zapisać w postaci:

$$x_t = Ax_{t-1} + Bu_t + w_t \quad (16)$$

$$z_t = Hx_t + v_t \quad (17)$$

, gdzie macierz  $A$  określa zależność procesu ukrytego w chwili  $t$  od stanu w chwili  $t - 1$ , w  $u_t$  znajduje się sterowanie procesem (zewnętrzna ingerencja w proces, za chwilę będzie podany pewien intuicyjny przykład), macierz  $B$  określa zależność stanu  $x_t$  od sterowania, natomiast  $w_t$  jest gaussowskim białym szumem o zerowej wartości oczekiwanej i znanej wariancji. Natomiast macierz  $H$  jest macierzą przejścia od procesu ukrytego, do obserwowanego.

Na pierwszy rzut oka całe to tak sformułowany model może wydawać się dziwny i nienaturalny - a przez to bezużyteczny! Poniżej jednak pewien przykład:

### 3.1 Przykład modelu

Jedziemy samochodem. Naszym celem jest szacowanie w każdej chwili prędkości i drogi którą pokonaliśmy od rozpoczęcia podróży. Pojawił się jednak pewien problem natury technicznej - prędkościomierz nie działa! W normalnych warunkach byłoby dosyć niebezpiecznie podróżować takim samochodem, jednak posiadamy GPS, który podaje nam nasze położenie. Dodatkowo uzbrajając się w wiedzę związaną z filtrem Kalmana budujemy stosowny model (dla ułatwienia przyjmiemy również, że hamulce nie działają, przez co nie ma się żadnego wpływu na prędkość:-):

- $x_{1t}$  - oznacza położenie w chwili  $t$ .
- $x_{2t}$  - poszukiwana prędkość w chwili  $t$
- $z_t$  - wskazanie GPS odnośnie pozycji.

Sięgając do wzorów z fizyki znajdziemy, że wzór na drogę w ruchu jednostajnym prostoliniowym to  $x_{1t} = x_{1t-1} + (x_{2t-1} \cdot \Delta t)$ , tak więc macierze  $A$ ,  $B$  i  $H$  będą wyglądały w ten sposób:

$$A = \begin{pmatrix} 1 & \Delta t \\ 0 & 1 \end{pmatrix} \quad (18)$$

$$B = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} \quad (19)$$

$$H' = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \quad (20)$$

### 3.2 Równania w filtrze Kalmana

Oznaczenia:

- $\hat{x}_{t|t}$ - wartość oczekiwana w chwili  $t$ , pod warunkiem chwili  $t$
- $\hat{x}_{t|t-1}$ - prognoza wartości oczekiwanej na chwilę  $t$ , przy znajomości procesu do chwili  $t - 1$
- $P_{t|t}$ - macierz kowariancji dla  $x_t$  w chwili  $t$
- $P_{t-1|t-1}$ - macierz kowariancji prognozy  $x_t$  na chwilę  $t$ , pod warunkiem chwili  $t - 1$

Faza predykcji:

$$\hat{x}_{t|t-1} = A\hat{x}_{t-1|t-1} + Bu_t \quad (21)$$

$$P_{t|t-1} = AP_{t-1|t-1}A' + W \quad (22)$$

Faza uaktualnienia:

$$K_t = (P_{t|t-1}H')(HP_{t|t-1}H' + R)^{-1} \quad (23)$$

$$\hat{x}_{t|t} = \hat{x}_{t|t-1} + K_t(z_t - H\hat{x}_{t|t-1}) \quad (24)$$

$$P_{t|t} = P_{t|t-1} - K_tHP_{t|t-1} \quad (25)$$

### 3.3 Wyprowadzenie wzorów - faza predykcji

Poniżej znajduje się wyprowadzenie wzorów związanych z fazą predykcji w filtrze Kalmana - nic trudnego:

Wpierw prognoza wartości oczekiwanej, na okres  $t$ , pod warunkiem znajomości wartości oczekiwanej w czasie  $t-1$ .

$$\begin{aligned} \hat{x}_{t|t-1} &= E(x_t|\hat{x}_{t-1|t-1}) = E(A\hat{x}_{t-1|t-1} + Bu_t + w_t) = \\ &= A\hat{x}_{t-1|t-1} + Bu_t + E(w_t) = A\hat{x}_{t-1|t-1} + Bu_t \end{aligned} \quad (26)$$

Komentarz: W powyższym wyprowadzeniu należy jedynie zauważyć, że  $\hat{x}_{t-1|t-1}$  jest znane,  $u_t$  również, a  $w_t$  nie zależy od  $\hat{x}_{t-1|t-1}$  i jego wartość oczekiwana jest równa 0. Jasno widać, że 26 zgadza się z 21.

Teraz będzie weselej - macierz kowariancji dla prognozy  $x_t$  ( $P_{t|t-1}$ ):

$$P_{t|t-1} = E[(x_t - \hat{x}_{t|t-1})(x_t - \hat{x}_{t|t-1})'] \quad (27)$$

Na początek dobrze jest policzyć samo:

$$x_t - \hat{x}_{t|t-1} = Ax_t + Bu_t + w_t - A\hat{x}_{t-1|t-1} - Bu_t = A(x_t - \hat{x}_{t-1|t-1}) + w_t \quad (28)$$

Teraz podstawiamy 28 do 27 i otrzymujemy:

$$\begin{aligned} P_{t|t-1} &= E[(x_t - \hat{x}_{t|t-1})(x_t - \hat{x}_{t|t-1})'] = E[(A(x_t - \hat{x}_{t-1|t-1}) + w_t)(A(x_t - \hat{x}_{t-1|t-1}) + w_t)'] \\ &= AE[(x_t - \hat{x}_{t-1|t-1})(x_t - \hat{x}_{t-1|t-1})']A' + AE[(x_t - \hat{x}_{t-1|t-1})w_t'] + \\ &\quad + E[w_t(x_t - \hat{x}_{t-1|t-1})']A' + E(w_tw_t') \end{aligned} \quad (29)$$

Teraz należy zauważyć, że  $E[(x_t - \hat{x}_{t-1|t-1})(x_t - \hat{x}_{t-1|t-1})']$  to macierz kowariancji w chwili  $t-1$  - czyli  $P_{t-1|t-1}$ ,  $E(w_tw_t')$ , to macierz kowariancji  $w_t$  - czyli  $W$ , a kowariancja  $E[w_t(x_t - \hat{x}_{t-1|t-1})']$  wynosi 0. Ostatecznie otrzymujemy:

$$P_{t|t-1} = AP_{t-1|t-1}A' + W \quad (30)$$

### 3.4 Wyprowadzenie wzorów - faza uaktualnienia - intuicyjnie

W tej sekcji zostaną wyprowadzone wzory związane z fazą predykcji - jednak przy pewnym założeniu odnośnie macierzy  $H$  - celem takiego podejścia jest pokazanie pewnych związków filtru Kalmana i rekurencyjnego obliczania parametrów rozkładu aposteriori pokazanego wcześniej.

Na potrzeby dalszych rozważań przyjmijmy, że macierz  $H$ , jest macierzą kwadratową (w ogólności dla filtru Kalmana tak być nie musi) i do tego jest nieosobliwa ( $\det(H) \neq 0$ ). Wyprowadzone wzory co prawda będą takie same jak w przypadku uchylenia powyższego założenia, jednak proces wyprowadzania będzie zupełnie inny!

Teraz czas na Bayesizm - Na początek przyjmijmy, że w chwili  $t$  rozkład apriori dla zmiennej losowej  $x_t$ , to  $N(\hat{x}_{t|t-1}, P_{t|t-1})$  - takie założenie wydaje się być sensowne - jako rozkład apriori przyjmujemy prognozy parametrów z okresu  $t-1$  na okres  $t$ . Teraz dobrze byłoby skorzystać ze wzorów 14 i 15, problemem jest jednak to, że  $x_t$  jest nieobserwowalne - tzn. nie ma nadziei, że pojawi się nowa obserwacja. Mamy jednak dostęp realizacji  $z_t$ . Można więc spróbować na podstawie wzorów 14 i 15 wyznaczyć rozkład aposteriori dla zmiennej losowej  $Hx_t$ , a potem powrócić do  $x_t$ . Rozkład apriori dla  $Hx_t$  to  $N(H\hat{x}_{t|t-1}, HP_{t|t-1}H')$ . Ze wzoru 14 mamy:

$$H\hat{x}_{t|t} = H\hat{x}_{t|t-1} + \frac{HP_{t|t-1}H'}{HP_{t|t-1}H' + R}(z_t - H\hat{x}_{t|t-1}) \quad (31)$$

, mnożąc lewostronnie przez  $H^{-1}$  (właśnie po to było założenie o nieosobliwości macierzy  $H$ ), otrzymujemy:

$$\hat{x}_{t|t} = \hat{x}_{t|t-1} + (P_{t|t-1}H')(HP_{t|t-1}H' + R)^{-1}(z_t - H\hat{x}_{t|t-1}) \quad (32)$$

Natomiast dla kowariancji:

$$HP_{t|t}H' = HP_{t|t-1}H' - (HP_{t|t-1}H')(HP_{t|t-1}H' + R)^{-1}(HP_{t|t-1}H')' \quad (33)$$

, i analogicznie jak w 31 przez  $H^{-1}$  i  $(H')^{-1}$ , otrzymując:

$$P_{t|t} = P_{t|t-1} - (P_{t|t-1}H')(HP_{t|t-1}H' + R)^{-1}HP_{t|t-1} \quad (34)$$

, dla wygody zauważamy, że w obu wypadkach 32 i 34 występuje ten sam fragment postaci:  $(P_{t|t-1}H')(HP_{t|t-1}H' + R)^{-1}$  - dobrze nazwać go sobie jakoś nazwać - np  $K_t$ :

$$K_t = (P_{t|t-1}H')(HP_{t|t-1}H' + R)^{-1} \quad (35)$$

, i po podstawieniu do 32 i 34, otrzymujemy:

$$\hat{x}_{t|t} = \hat{x}_{t|t-1} + K_t(z_t - H\hat{x}_{t|t-1}) \quad (36)$$

$$P_{t|t} = P_{t|t-1} - K_tHP_{t|t-1} \quad (37)$$

, teraz uważny obserwator porównując wzory 35, 36, 37 ze wzorami 23, 24 i 25, zauważy, że są identyczne!

Niestety trzeba pamiętać o przyjętym założeniu, że  $H$  jest macierzą nieosobliwą. W następnej sekcji powyższe wzory zostaną wyprowadzone w trochę inny sposób.

### 3.5 Wyprowadzanie wzorów - uaktualnianie

Powyżej wzory związane z filtrem Kalmana zostały wyprowadzone przy założeniu, że macierz  $H$  jest macierzą nieosobliwą - jest to bardzo krępujące, gdyż w większości zastosowań  $H$  nie jest nawet kwadratowa (choćby w przykładzie w 3.1)!

By pozbyć się tego założenia, trzeba podejść do problemu w inny sposób. Zaczniemy od intuicji -  $x_t$  jest nieobserwowane, przez co nie ma szans na bezpośrednie zastosowanie formuły 14. Jeżeli  $H$  nie jest kwadratowa, to nie będą możliwe do wykonania kroki przedstawione w poprzedniej sekcji. Mamy więc do dyspozycji realizację  $z_t$  i predykcję wartości oczekiwanej z poprzedniego okresu  $\hat{x}_{t|t-1}$ . Trzeba zastosować podejście w pewnym sensie inżynierskie. Przyjmijmy, że im większa różnica pomiędzy wartościami które możemy wyznaczyć ( $z_t - H\hat{x}_{t|t-1}$ ), tym zmiana  $\hat{x}_{t|t}$ , powinna być większa. Jako, że różnica  $z_t - H\hat{x}_{t|t-1}$  nie koniecznie musi być w tym samym wymiarze, co  $\hat{x}_{t|t}$ , należy wykorzystać jakąś macierz - dowolnej postaci!!! - która sprawi, że wymiary pomiędzy  $\hat{x}_{t|t}$  i  $z_t - H\hat{x}_{t|t-1}$  będą się zgadzały. Taką macierz można nazwać na przykład  $Z_t$ . Otrzymujemy więc:

$$\hat{x}_{t|t} = \hat{x}_{t|t-1} + Z_t(z_t - H\hat{x}_{t|t-1}) \quad (38)$$

. Powyższe równanie wygląda znajomo - tylko zamiast  $K_t$  występuje  $Z_t$ .

W tej chwili  $Z_t$  jest dowolną macierzą, której jedyną własnością, jest to, że wymiary macierzy w równaniu 38 zgadzają się ze sobą. Należałoby przyjąć jakieś kryterium, względem którego można by wyznaczyć najbardziej optymalną postać  $Z_t$ . Tym kryterium może być, np. minimalizacja wartości oczekiwanej kwadratów reszt - czyli:

$$E(\|x_t - \hat{x}_{t|t}\|^2) \rightarrow \min. \quad (39)$$

. Tak przedstawiony problem, jest równoważny minimalizacji śladu macierzy kowariancji  $Cov(x_t - \hat{x}_{t|t}) = P_{t|t}$ . Należy zwrócić uwagę, że macierz  $P_{t|t}$  - na razie nie ma nic wspólnego z macierzą wyznaczoną w poprzednim podrozdziale - jednak takie oznaczenie jest bardzo wygodne. Można powiedzieć, że należy zapomnieć o wszystkim z 3.4 (natomiast wszystkie wzory z 3.3 pozostają w mocy).

$$\begin{aligned} P_{t|t} &= Cov(x_t - \hat{x}_{t|t}) = Cov[x_t - \hat{x}_{t|t-1} - Z_t(z_t - H\hat{x}_{t|t-1})] = \\ &= Cov[x_t - \hat{x}_{t|t-1} - Z_t z_t + Z_t H \hat{x}_{t|t-1}] = Cov[x_t - \hat{x}_{t|t-1} - Z_t H x_t - Z_t v_t + Z_t H \hat{x}_{t|t-1}] = \\ &= Cov[(I - Z_t H)(x_t - \hat{x}_{t|t-1}) - Z_t v_t] = Cov[(I - Z_t H)(x_t - \hat{x}_{t|t-1}) - Z_t v_t] \end{aligned} \quad (40)$$

, Powyższe przejścia wyglądają źle, ale nie są trudne, następuje podstawienie wzoru 38, następnie, za  $z_t$ , podstawione zostaje 17. Potem następują zwykłe przekształcenia algebraiczne. By uprościć obliczenia należy zauważyć, że kowariancja pomiędzy  $v_t$ , a resztą wynosi 0 i wtedy możemy zapisać:

$$\begin{aligned} P_{t|t} &= Cov[(I - Z_t H)(x_t - \hat{x}_{t|t-1})] + Cov[Z_t v_t] = \\ &= (I - Z_t H)Cov[(x_t - \hat{x}_{t|t-1})](I - Z_t H)' + Z_t Cov[v_t]Z_t' = \\ &= (I - Z_t H)P_{t|t-1}(I - Z_t H)' + Z_t R Z_t' \end{aligned} \quad (41)$$

Tę postać należy zapamiętać:

$$P_{t|t} = (I - Z_t H)P_{t|t-1}(I - Z_t H)' + Z_t R Z_t' \quad (42)$$

, poniżej jeszcze wersja rozpisana, która przyda się już za chwilę:

$$\begin{aligned} P_{t|t} &= P_{t|t-1} - P_{t|t-1}Z_t'H' - Z_tHP_{t|t-1} + Z_tHP_{t|t-1}H'Z_t' + Z_tRZ_t' = \\ &= P_{t|t-1} - P_{t|t-1}Z_t'H' - Z_tHP_{t|t-1} + Z_t(HP_{t|t-1}H' + R)Z_t' \end{aligned} \quad (43)$$

Teraz szukamy,  $Z_t$  minimalizującego ślad macierz  $P_{t|t}$ :

$$\begin{aligned} \frac{dP_{t|t}}{dZ_t} &= -2P_{t|t-1}H' + 2Z_t(HP_{t|t-1}H' + R) = 0 \\ Z_t(HP_{t|t-1}H' + R) &= P_{t|t-1}H' \\ Z_t &= P_{t|t-1}H'(HP_{t|t-1}H' + R)^{-1} \end{aligned} \quad (44)$$

, Porównując ten wzór z 23, łatwo zauważyć, że  $Z_t = K_t$ , czyli  $K_t$  w filtrze Kalmana minimalizuje sumę kwadratów reszt.

## 4 Prosta implementacja filtra Kalmana w R

```
# Wzory na faze predykcji:
calcXt1 = function(A, xt, B = NULL, u) {
  if (is.null(B))
    return(A %%% xt)
  return(A %%% xt + B %%% u)
}

# Faza uaktualniania:
calcPt1 = function(A, Pt, Q) A %%% Pt %%% t(A) + Q
kalmanGain = function(Pt1, H, R) Pt1 %%% t(H) %%% solve(H %%% Pt1 %%% t(H) +
  R)
calcXt = function(xt1, K, z, H) xt1 + K %%% (z - H %%% xt1)
calcPt = function(Pt1, K, H) Pt1 - K %%% H %%% Pt1
```